

김태민 포토폴리오

데이터 전처리와 모델 최적화로
신뢰할 수 있는 AI 결과를 만드는 개발자

AI Hub 알약 객체 탐지 · RAG 문서 검색 시스템 · Bytecode 사전학습 모델 연구 · 청소년
자유학교



김태민 | Taemin Kim

데이터 전처리와 모델 최적화에 강점을 가진 ML 엔지니어 지망생입니다.
객체 탐지, RAG 검색, Bytecode 연구, 교육 봉사를 통해 기술적 문제 해결력과 책임감을
함께 키웠습니다.

Email: uritemin@gmail.com
Git: <https://github.com/taeminkim-408>
Phone: 010-7595-3995

EDUCATION

한동대학교 AI·컴퓨터공학

글로벌 선진고등학교

CAREER

육군 정보 시스템 운영

ISEL 학사 연구원 활동

Codelt AI bootcamp

AWARD

경상북도지사 우수교사상

ICST 2025 국제학회(나폴리) 논문 발표

EXPERIENCE

알약 객체 탐지

RAG 문서 검색 시스템

Bytecode 사전학습 모델 연구

EXPERTISE

데이터 전처리 · 모델 최적화 ·
Object Detection · RAG / LLM ·
연구·문서화

SKILL

Python · PyTorch · OpenCV ·
Docker · PipeLine



김태민

ML Engineer Candidate

데이터를 정제하고, 모델을 실험하며,
결과를 서비스로 연결하는 개발자

데이터 기반 문제 해결을 실험으로 증명합니다.

저는 데이터 전처리와 모델 최적화에 강점을 가진 ML 엔지니어 지망생입니다. 알약 객체 탐지 프로젝트에서는 이미지·Annotation 데이터를 분석하고, YOLO 기반 모델 개선을 경험했습니다.

RAG 문서 검색 시스템 프로젝트에서는 HWP/PDF 파싱, 표 데이터 처리, Chroma 기반 검색 파이프라인 검증에 참여했습니다. 단순 구현보다 데이터 구조와 재현성 있는 흐름을 중요하게 생각합니다.

Bytecode 사전학습 모델 연구에서는 데이터 표현 방식과 tokenizer 구조가 모델 성능에 미치는 영향을 정리하며, 논문 초안 작성과 결과 해석을 수행했습니다. 또한 청소년 자유학교에서 5년간 교육 봉사를 이어가며 책임감과 소통 역량을 길렀습니다.

데이터
전처리

모델 최적화

연구 경험

책임감

소통

프로젝트별 담당 역할

- 01

알약 객체 탐지

기간: 2026.03~ 04

데이터셋 품질 관리 · bbox 검증 · 데이터 보강 · 증강 실험 분석

COCO JSON / YOLO / ResNet / OpenCV
- 02

RAG 문서 검색

기간: 2026.05~ 06

표 데이터 처리 · 파이프라인 설계 및 검증 · 스프린트 운영 참여

HWP/PDF / Chroma / BM25 / OpenAI API
- 03

Bytecode 기반 보안
취약점 탐지 모델

기간: 2024.08~ 2025.12

논문 작성 · tokenizer 구조 분석 · 보안데이터셋 파이프라인 관리

ByteTok / byteT5 / byteBERT / GPT-4o
- 04

상무대 사이버방호실

전산보호병 · 전산 운영병 · 서버관리병

linux 체계 서버관리

이미지 기반 알약 객체 검출 및 분류를 위한 2-Stage 헬스케어 AI 시스템

FINAL MODEL

**YOLOv11s +
ResNet50**
Detection + Classification

DATA

4,719장

최종 학습 이미지

SCORE

mAP 0.98569

Public Score

ROLE

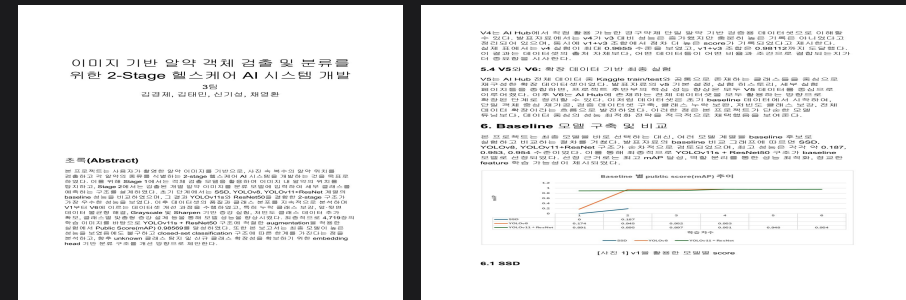
데이터·실험

품질 관리 및 개선

PROJECT SUMMARY

- 사용자가 촬영한 이미지에서 복수의 알약 위치를 탐지
- 탐지된 crop를 분류 모델에 입력해 세부 클래스를 예측
- SSD, YOLOv8, YOLOv11+ResNet baseline 비교 후 최종 구조 선정

VISUAL EVIDENCE



최종보고서와 baseline 비교 결과를 기반으로 프로젝트 성과를 포트폴리오에 정리했습니다.

데이터 품질을 개선해 모델 성능 향상에 기여

01

데이터셋 분석

AI Hub/Kaggle 이미지 데이터 구조를 확인하고, 클래스 분포와 누락 데이터를 점검했습니다.

02

Annotation 검증

COCO JSON, bbox 라벨, 이미지-라벨 매핑을 확인해 학습 데이터 품질을 높였습니다.

03

데이터 보강

앞·뒷면 불균형, 저빈도 클래스, 누락 클래스 문제를 분석하고 보강 방향을 정리했습니다.

04

실험 분석

Grayscale, Sharpen, 회전 등 증강 실험 결과와 오탐·미탐 사례를 비교했습니다.

성가로 연결된 역할: 단순 모델 학습이 아니라, 데이터셋의 품질·불균형·증강 조건을 분석하며 **2-Stage** 구조의 성능 개선 과정에 참여했습니다.

HWP/PDF 문서를 검색 가능한 지식베이스로 변환하는 자동화 파이프라인

INPUT

RFP 100건

본문·OCR 이중 경로

EVAL

500문항

Harness 기반 평가

DB

Chroma

메타데이터 검색

ROLE


표 데이터 처리

파이프라인 설계·검증

PROJECT FLOW

- HWP는 rhwp, PDF는 PyMuPDF 기반으로 본문 추출
- 본문 파이프라인과 이미지 OCR 경로를 함께 구성
- Chroma + BM25 기반 통합 인덱스로 RAG 검색 수행

PIPELINE IMAGE



원본 → 파싱/OCR → Chroma+BM25 → RAG 답변 → Harness 평가

표 데이터와 파이프라인 재현성에 집중

01

일정·회의 운영

일정, 마일스톤, 스프린트, 회의 흐름을 관리하며 팀 진행 상황을 정리했습니다.

02

표 데이터 처리

RFP 문서 내 표 정보를 검색 가능한 형태로 변환하고, 표 누락 문제를 확인했습니다.

03

파이프라인 검증

파일 입력부터 Chroma 저장까지 같은 명령으로 재현 가능한 구조를 검토했습니다.

04

문맥·출처 관리

문서명, section_path, 자료유형 prefix를 활용해 검색 결과의 추적성을 높였습니다.

핵심 키워드: HWP/PDF Parsing · Table IR · Chroma Vector DB · RAG Retrieval

문서 구조를 검색 가능한 데이터 구조로 바꾸는 과정에 집중했습니다.

Pre-trained Models for Bytecode Instructions

RESEARCH BACKGROUND

- 소스코드 중심 모델은 컴파일 이후 표현인 bytecode의 구조적 특성을 충분히 활용하지 못함
- Java bytecode는 프로그램 분석, 취약점 탐지, 자동 수정에 활용 가치가 큼
- bytecode instruction을 모델 입력으로 다루기 위한 tokenizer와 benchmark 구성이 필요

RESEARCH DIRECTION

- Hexadecimal bytecode 표현 기반 사전학습 모델 설계
- ByteTok tokenizer, byteT5, byteBERT 구조 검토
- GPT-4o와 fill-in-the-blank 방식으로 성능 비교
- Bytecode 기반 자동 프로그램 수정 가능성과 한계 분석

논문: Pre-trained Models for Bytecode Instructions

연구를 실험과 글로 구조화한 경험

01

논문 작성

연구 배경, 문제 정의, 관련 연구, 실험 결과 해석을 논문 문장으로 구조화했습니다.

02

Tokenizer 분석

ByteTok 구조와 bytecode 표현 방식이 모델 입력에 미치는 영향을 정리했습니다.

03

모델 비교

byteT5, byteBERT 기반 사전학습 흐름과 GPT-4o 비교 실험을 문서화했습니다.

04

결과 해석

bytecode 기반 자동 프로그램 수정 가능성과 closed setting 한계를 분석했습니다.

총 50만개 이상의 자바 class파일을 바이트코드로 변환 및 변환하였습니다.

ICST 2025 International Research Presentation



Java Bytecode 기반 사전학습 모델 연구 발표

- Java source code를 bytecode instruction 및 hexadecimal representation으로 변환
- ByteTok tokenizer를 활용한 bytecode sequence 입력 구성
- byteBERT, byteT5 기반 사전학습 모델 실험 및 결과 분석
- 기존 LLM 기반 접근과 비교하여 bytecode representation의 가능성 검토
- 영어 논문 작성 과정에 참여하고 ICST 2025 나폴리 현장에서 발표 및 Q&A 진행

성과

- 연구 문제 정의부터 데이터셋 구축, 모델 실험, 결과 분석, 논문 작성, 국제학회 발표까지 연구 전 과정을 경험했습니다.

군 간부 교육용망 스마트러닝체계 Linux 서버 운영 및 네트워크 구조 개선

INPUT

교육생

1,000~3,000명

분기별 접속 사용자 규모

SYSTEM

Linux Server

군 간부 교육용망 운영

NETWORK

Internal Network

교육망 회선 및 장애 관리 검색

ROLE

인프라 운영

서버 관리 · 장애 복구 · 구조 개선

PROJECT FLOW

- 상무대 사이버보안실에서 군 간부 교육용망 스마트러닝체계 운영 지원
- Linux 서버 상태 점검, 교육망 접속 환경 관리, 네트워크 회선 정리 수행
- 내부망 장애 발생 시 회선 구조를 추적하고 문제 구간을 복구
- 장애 복구 이후, 회선이 하나의 구조로 연결되어 장애가 확산될 수 있는 문제를 분석
- 랜선을 기능별로 분리·관리하는 구조 개선안을 제안하여 안정성과 보안성 개선

교육망 운영 흐름도

Military IT Infrastructure Flow



5년간 이어간 교육 봉사와 책임감



ACTIVITY DETAIL

- 검정고시를 준비하는 청소년을 대상으로 교육 봉사 진행
- 학생별 학습 수준에 맞춰 수업 내용을 준비하고 꾸준히 지도
- 소풍·운동회 등 학교 활동을 지원하며 학생들과 신뢰 관계 형성
- 장기간 봉사를 통해 책임감, 설명력, 소통 역량을 강화

성과

- 경북도지사 우수교사상 표창

사용 기술스택

ML / DL

Python

PyTorch

YOLO

ResNet

OpenCV

RAG / LLM

LangChain

ChromaDB

BM25

OpenAI API

Hugging Face

DATA / DEVOPS

COCO JSON

Pandas

Docker

Git/GitHub

CSV Pipeline

데이터를 정제하고, 모델을 실험하며, 실제 서비스로 이어지는 **AI**
파이프라인을 만드는 개발자

Email uritemin@gmail.com
GitHub github.com/taeminkim
Phone 010-7595-3995